L’intelligence artificielle générative

Partie 4 : L’IA générative

Présenté par **Morgan Gautherot**

Comment L’IAG va changer le monde ?

Partie 4 : L’IAG pour les développeurs

Les entreprises subissent un changement transmormatif grâce à l'IA générative

Avec l’IA génératif

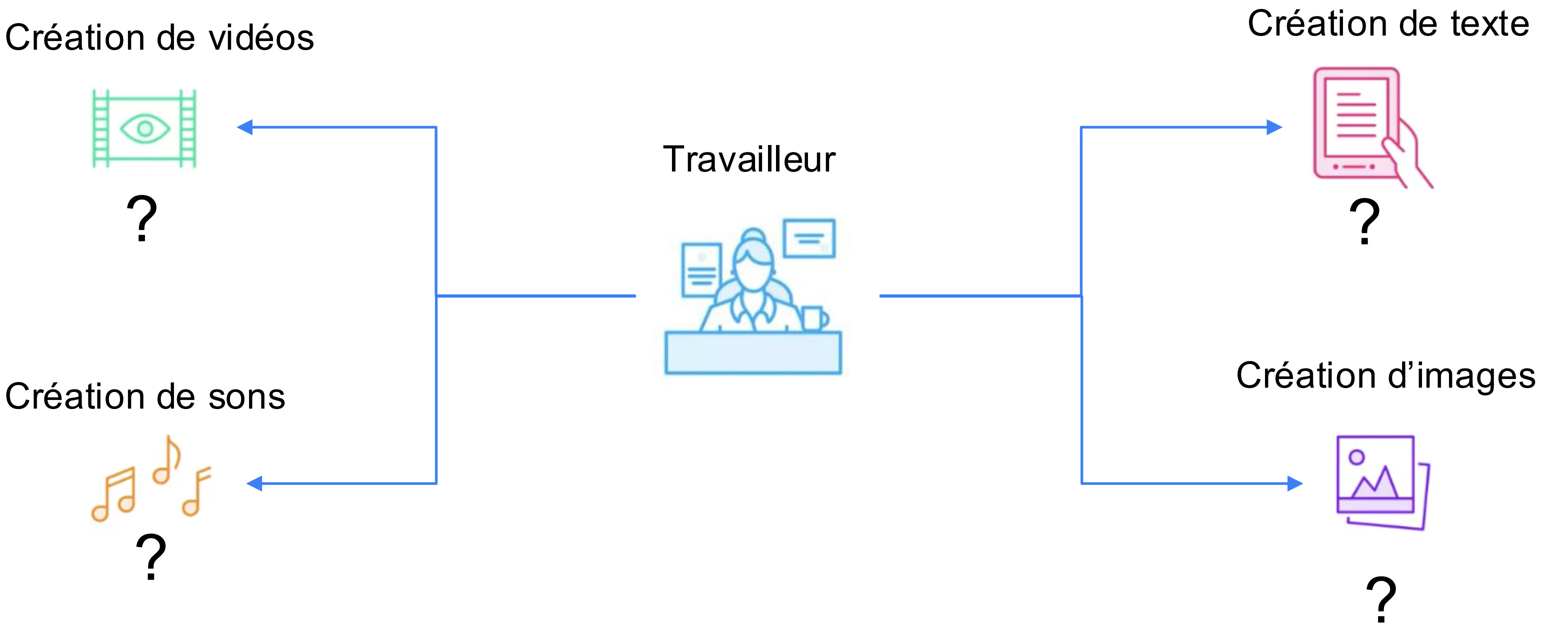

Génération de texte

Partie 4 : L’IAG pour les développeurs

Création du texte

- Processus par lequel un système piloté par l'IA produit un nouveau contenu textuel
  - Ressemble à un texte produit par un être humain
- Généré à partir d’un prompt
  - Ecrit avec du langage naturel

Le langage naturel devient la clef

La vraie utilité de la GenAI

	Avant	Après	exemple
Recherche sur internet	Savoir exactement les mots clefs à utiliser	En posant des questions	ChatGPT
Chercher des informations dans une base de données	Savoir coder en SQL	En posant des questions	Cortex Analyst
Chercher des informations dans un document	Recherche mot par mot	En posant des questions	ChatPDF

Le langage naturel est la clé

- L’utilisation du language naturel est l’aspect le plus important de la GenAI.
- L’utilisateur pose des questions (prompt) de la même manière que s’il communiquait avec un humain.
    - Il obtient une réponse de la qualité d’un expert
- On travaille sur le traitement naturel du langage
    - Pas besoin de se familiariser avec une UI

Applications de texte avec la genAI

Création de contenus : blogs, histoires, posts, recettes, poèmes et toutes autres formes de textes créatifs.

Interaction avec des agents ou chatbots offrant des réponses plus sophistiquées que de simples réponses prédéfinies.

Traduction automatique, résumés de texte, auto-complétion, transcription et extraction d'entités.

Toutes les applications auxquels on peut penser lorsque l’on veut travailler du texte

Création de document texte

- ChatGPT OpenAI
- Gemini Google
- Mistral Mistral
- Claude Antropic
- Llama Meta

Test en local

```
ollama run llama3.1:8b

ollama run mistral
```

LLM pour générer du code

Claude	Claude
Llama code	Meta
Codestral	Mistral

Rapprocher les utilisateurs de la données

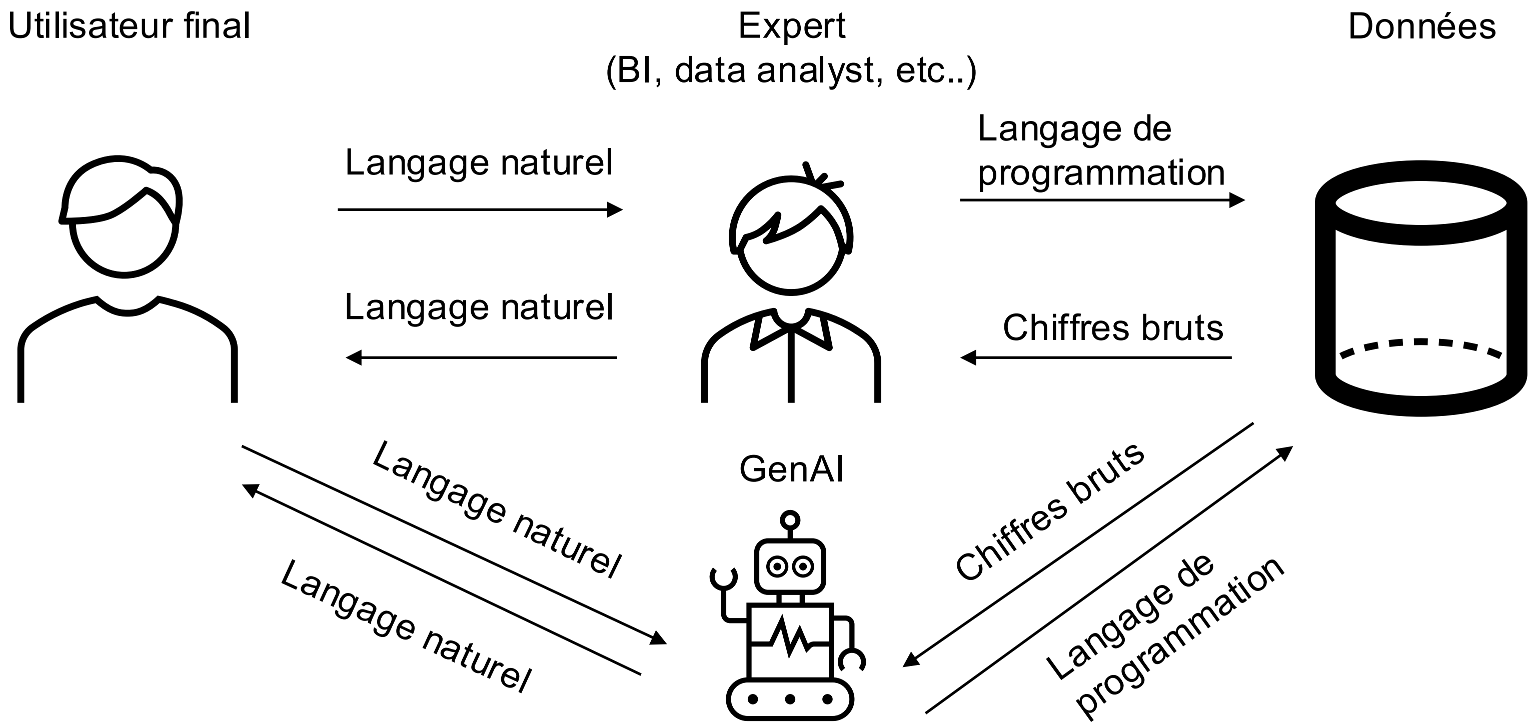

Les types de réponses

Les réponses sont fondées sur les données utilisées pour leur entraînement :

- livres, articles web, blogs, réseaux sociaux…
- ainsi que des sources publiques (comme Wikipédia, etc.).

Lors de l'utilisation d'une solution de GenAI, il est souvent difficile de connaître le jeu de données utilisé pour l'entraînement.

Il peut parfois être pertinent d’entraîner votre propre modèle ou de le fine-tuner sur un jeu de données qui vous appartient, afin de mieux contrôler ce paramètre.

Une explication simplifiée du fonctionnement des LLMs

Fonctionnement LLMs

Un Large Language Model c’est un très puissant et complexe modèle d’auto-completion

Fonctionnement des LLMs

Les LLM génèrent des réponses basées sur les informations sur lesquelles ils ont été entraînés.

Prédire un mot à la fois
- mais à une échelle beaucoup plus grande,
- avec une meilleure compréhension du contexte

Fonctionnement LLMs

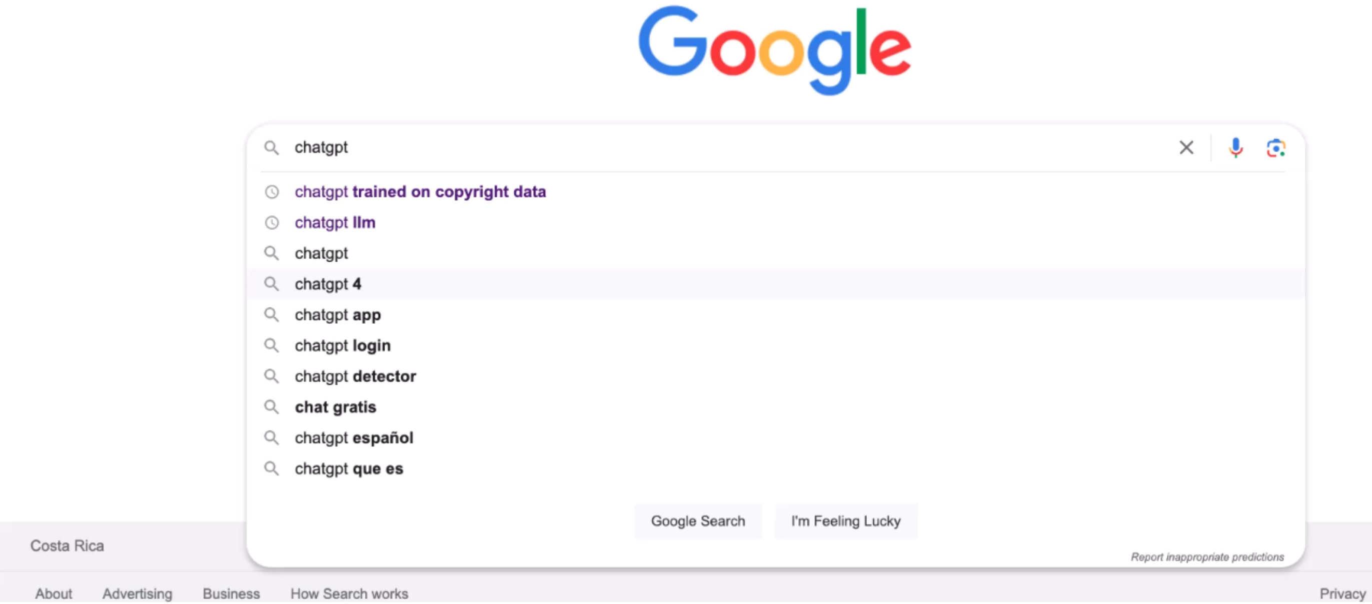

Similaire à ce que fait Google mais de manière beaucoup plus intelligente

D’où vient la magie

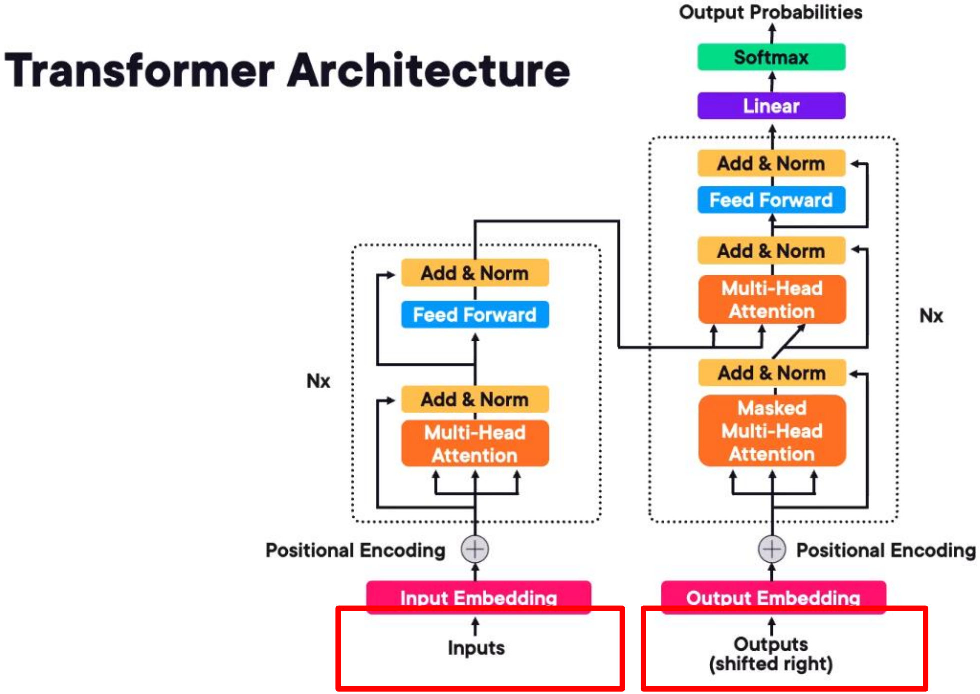

https://arxiv.org/pdf/1706.03762.pdf

Exemple avec chatGPT

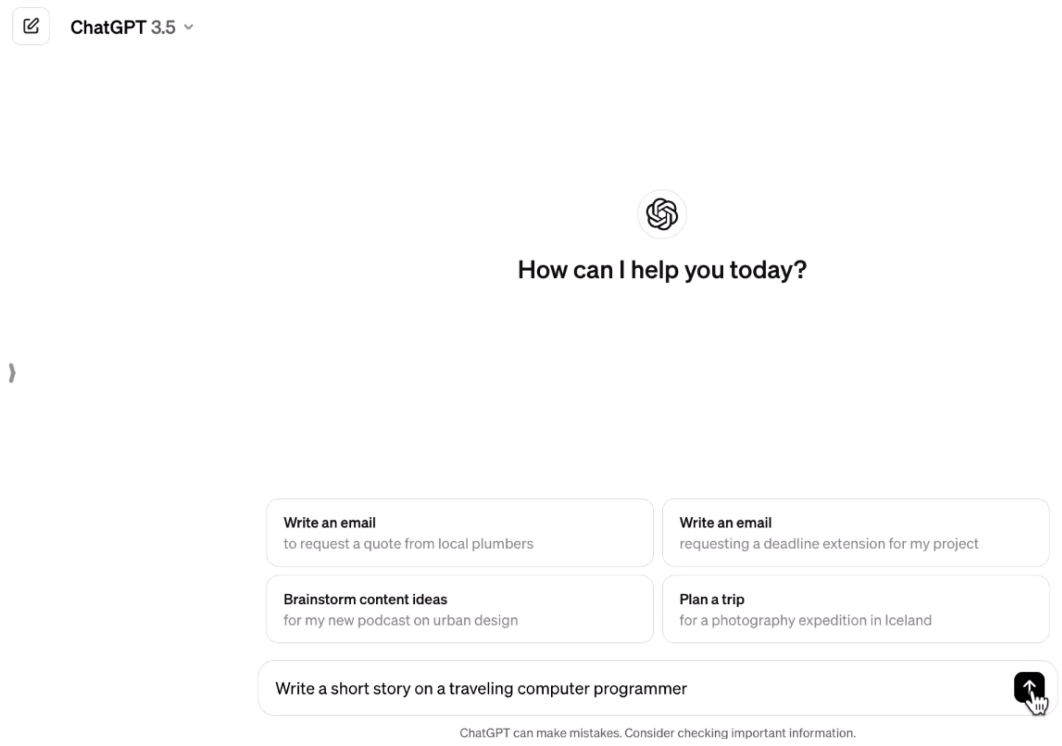

Exemple avec chatGPT

ChatGPT 3.5

input

You
Write a short story on a traveling computer programmer

output

ChatGPT
Once upon a time, in a world where technology intertwined with every aspect of life, there was a young computer programmer named Alex. Unlike most programmers who were content with their sedentary lifestyles, Alex had an insatiable wanderlust burning within.

From a young age, Alex was fascinated by computers. While other kids played outside, Alex was indoors, tinkering with code and building programs. As Alex grew older, the desire to explore the world outside the confines of their computer screen grew stronger.

One day, Alex made a bold decision. They packed up their laptop, a few changes of clothes, and set off on a journey across the globe. With nothing but their programming skills and a thirst for adventure, Alex embarked on an extraordinary journey.

Their first stop was in a bustling city where they found a cozy café with free Wi-Fi. With their laptop open, Alex dove into the local programming community, exchanging ideas and collaborating on projects. They quickly became known as the traveling programmer, a nomad of the coding world.

From there, Alex journeyed to remote villages where internet access was scarce. Undeterred, they

Message ChatGPT...

ChatGPT can make mistakes. Consider checking important information.

Dans le code ça donne quoi ?

jupyter genai-llm Last Checkpoint: 6 minutes ago

File Edit View Run Kernel Settings Help

Code

```
[7]: def process_chat_request(prompt):
         chat_messages.append({"role": "user","content": prompt})

         response = client.chat.completions.create(
         model="gpt-3.5-turbo",
         messages = chat_messages,
         temperature=0.7
         )
         # Append the response to messages
         response_content = response.choices[0].message.content
         chat_messages.append({"role": "assistant","content": response_content})

         print(json.dumps(chat_messages, indent=2))

         # Return the response content
         return response_content
```

```
[8]: # Set the system message
     system_message = "You are a helpful assistant"
     chat_messages = [{"role": "system", "content": system_message}]
```

```
[9]: print("Hello, how can I help you?")
```

```
Hello, how can I help you?
```

```
[*]: while True:
         print("Prompt: \n")
         user_prompt = input()
```

Dans le code ça donne quoi ?

jupyter genai-llm Last Checkpoint: 6 minutes ago

File Edit View Run Kernel Settings Help

Code

```
Hello, how can I help you?
```

```
[*]: while True:
         print("Prompt: \n")
         user_prompt = input()
         response = process_chat_request(user_prompt)
         print("Response: \n" + response)

         if user_prompt.lower() in ["bye", "exit", "quit"]:
                 break
```

```
Prompt:

 Write a short story on a traveling computer programmer
```

Dans le code ça donne quoi ?

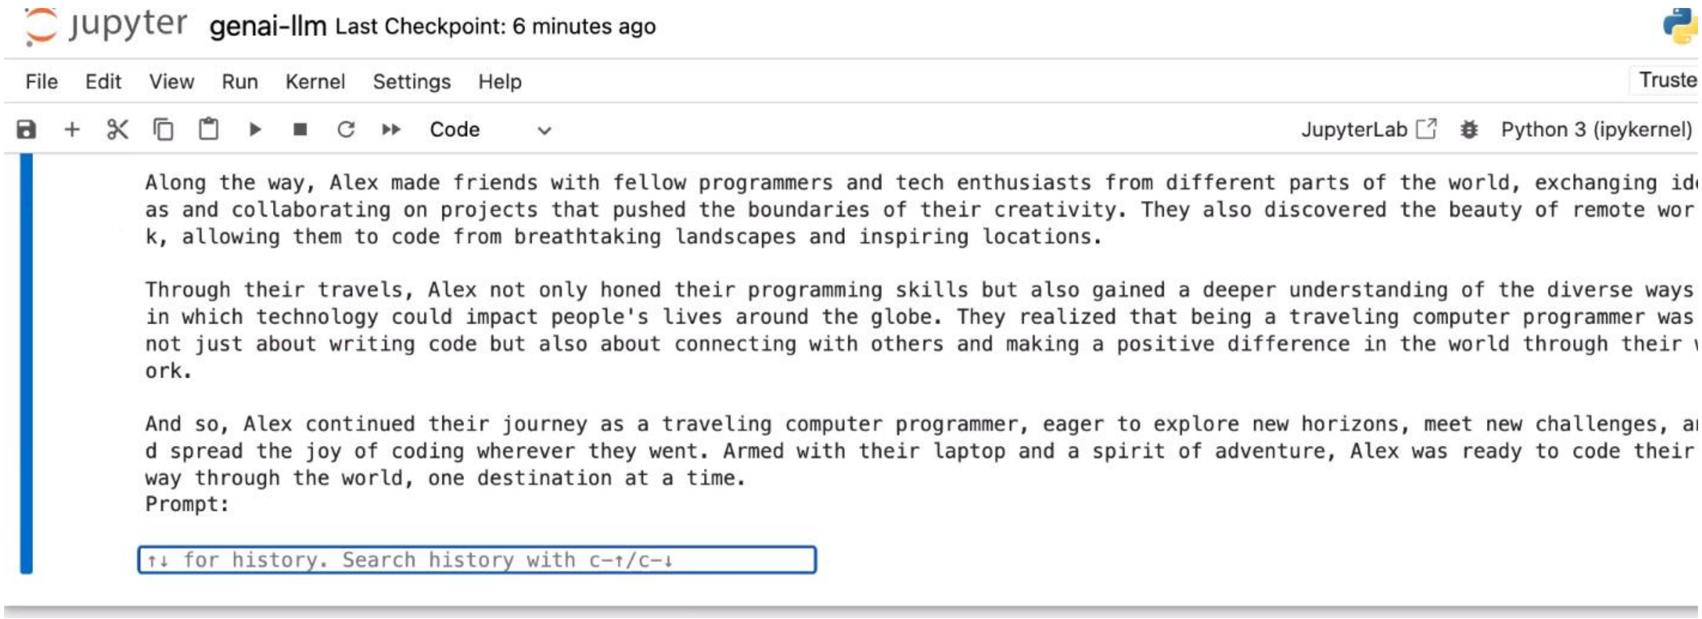

Dans le code ça donne quoi ?

Dans le code ça donne quoi ?

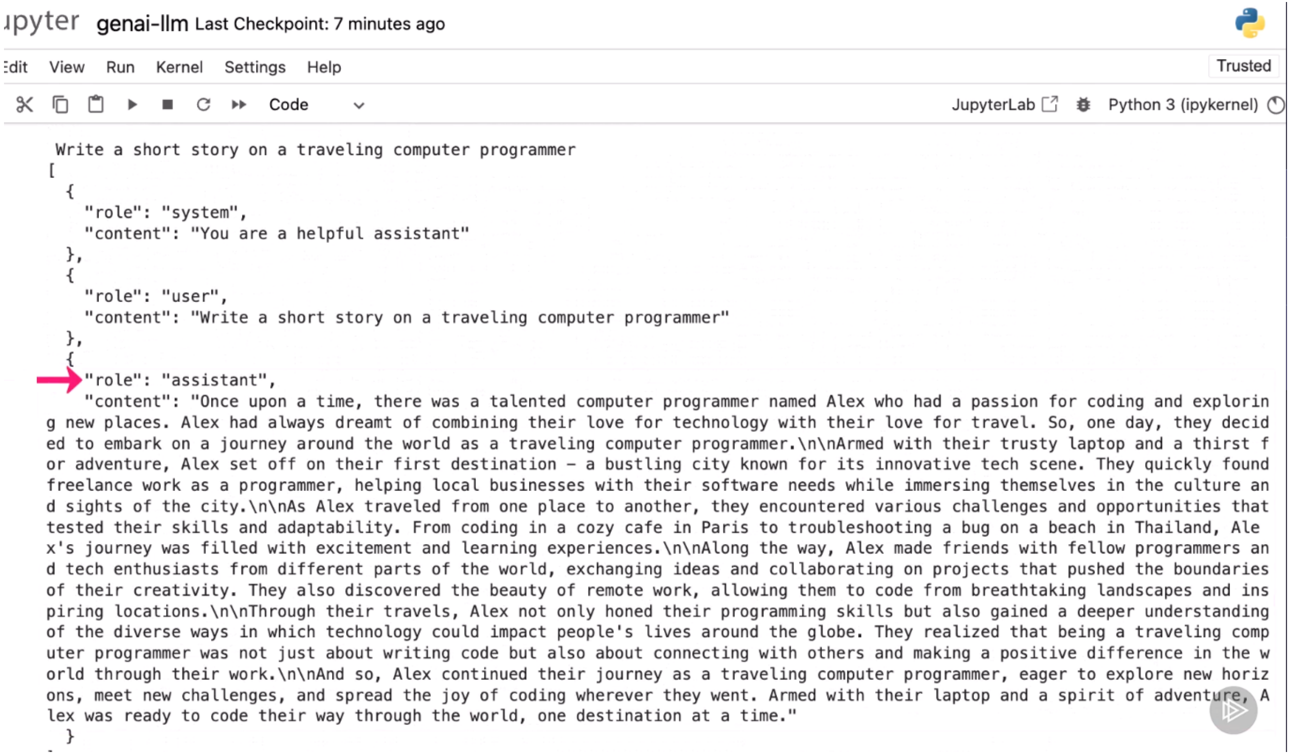

Dans le code ça donne quoi ?

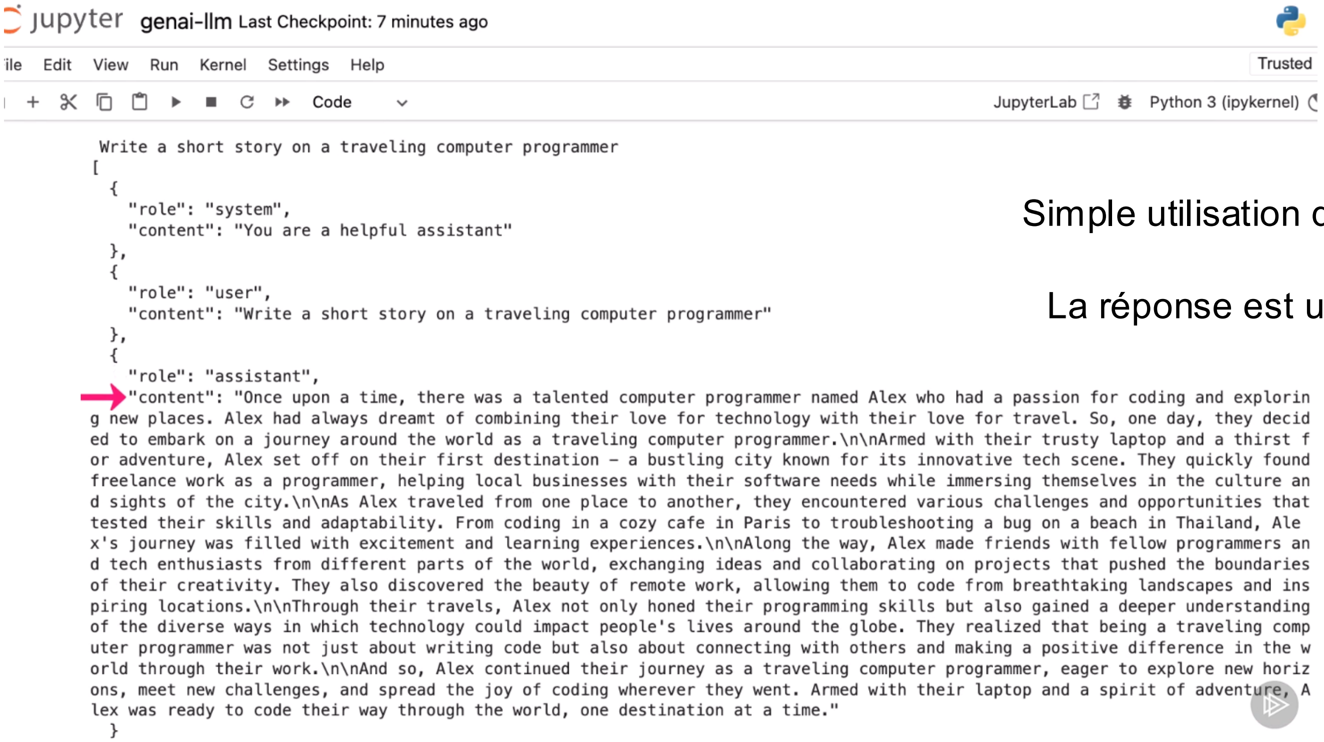

Simple utilisation d’une API

La réponse est un Json

Le tokenizer

Overview Documentation API reference

Tokenizer

Learn about language model tokenization

OpenAI's large language models (sometimes referred to as GPT's) process text using **tokens**, which are common sequences of characters found in a set of text. The models learn to understand the statistical relationships between these tokens, and excel at producing the next token in a sequence of tokens.

You can use the tool below to understand how a piece of text might be tokenized by a language model, and the total count of tokens in that piece of text.

It's important to note that the exact tokenization process varies between models. Newer models like GPT-3.5 and GPT-4 use a different tokenizer than previous models, and will produce different tokens for the same input text.

GPT-3.5 & GPT-4 GPT-3 (Legacy)

```
Write a short story on a traveling computer programmer
```

Le tokenizer

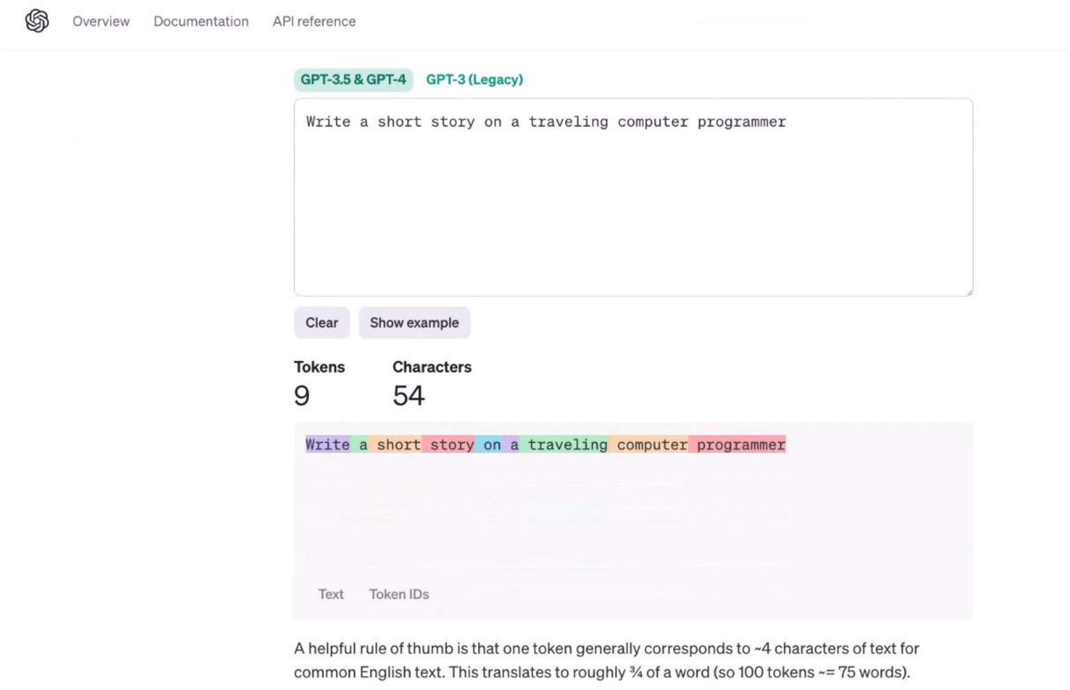

Le tokenizer

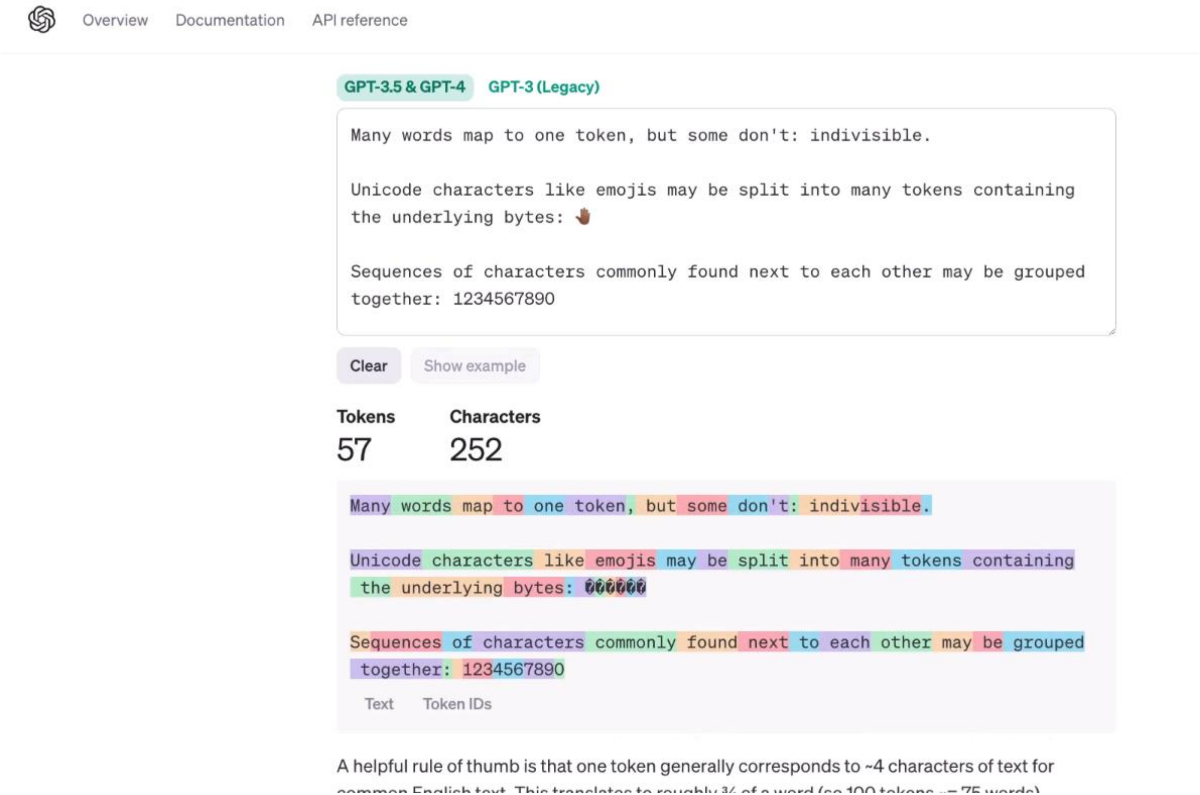

L’embedding

jupyter Untitled Last Checkpoint: 6 minutes ago

File Edit View Run Kernel Settings Help Trusted

Code JupyterLab Python 3 (ipykernel)

[9]:
```python
response = client.embeddings.create(
    input="Write a short story on a traveling computer programmer",
    model="text-embedding-3-small"
)
```

[10]:
```python
print(response.data[0].embedding)
```

```
[-0.011, -0.03158333, 0.001484375, -0.010618055, -0.017125, -0.06411111, 0.03888889, 0.034333333, 0.008520833, 0.009180555, 0.0
058055557, -0.009180555, -0.018555555, 0.00044487847, 0.015819445, -0.0019357639, -0.0033159722, -0.011083334, -0.021513889, 0.
021930555, -0.009090277, 0.03708333, 0.01913889, 0.020805556, -0.0047847223, 0.008486111, -0.0255, 0.02663889, 0.061611112, -0.
064, 0.0044131945, -0.011805556, 0.017958334, -0.013020833, 0.046916667, 0.0113194445, 0.018097222, -0.015652778, 0.04963889,
0.002248264, -0.015805556, -0.036194444, 0.029055556, 0.026944444, -0.029305555, 0.02398611, 0.00659375, 0.0060729166, 0.030833
334, 0.042944446, -0.036, 0.017833333, 0.00975, 0.0055902777, -0.03425, -0.018027777, -0.0285, -0.0027413194, 0.012680556, -0.0
20083332, 0.053916667, -0.03452778, 0.011854167, 0.016125, -0.020444445, 0.002684028, -0.032361113, -0.0037534721, -0.01947222
3, -0.016236112, 0.042805556, 0.053055555, -0.0061041666, 0.025180556, 0.00052300346, 0.00045833332, -0.03252778, 0.006003472,
0.0061284723, -0.0041770833, -0.004138889, -0.036944445, 0.027375, -0.019861111, -0.027319444, 0.0058854166, -0.0555, -0.054638
89, 0.0008606771, -0.04763889, 0.021791667, 0.04325, 0.044083335, 0.023486111, 0.056138888, 0.0002078993, -0.009875, 0.0273888
9, 0.008173611, 0.019208333, 0.0111875, -0.018555555, 0.002340278, 0.045555554, 0.048583332, 0.029444445, -0.023416666, 0.02738
889, -0.028666666, 0.016486112, -0.11744444, -0.012277778, 0.016402777, -0.034722224, -0.026263889, 0.044805557, 0.071777776, -
0.04227778, 0.02048611, -0.045027778, -0.030277777, 0.019736111, -0.0003643663, -0.020916667, -0.009888889, -0.037722223, -0.01
7430555, -0.031833332, -0.0017361111, -0.010180555, 0.031527776, -0.041972224, 0.022569444, -0.035194445, -0.016319444, -0.0062
395833, -0.009618056, -0.022736112, -0.04025, 0.03286111, -0.029222222, 0.05827778, -0.037388887, 0.0053715277, -0.0026666666,
0.037805557, 0.016541667, 0.0705, 0.009854167, 0.018472223, -0.018111112, -0.0136875, -0.008875, 0.019902777, 0.09466667, -0.02
1194445, -0.018097222, -0.008256945, -0.03538889, 0.0077708336, -0.04227778, -0.014104167, -0.034944445, -0.017930556, 0.003743
0555, -0.032194443, 0.017069444, 0.03425, -0.06277778, -0.03358333, 0.006361111, -0.06838889, -0.045833334, 0.02175, 0.04541666
```

L’embedding

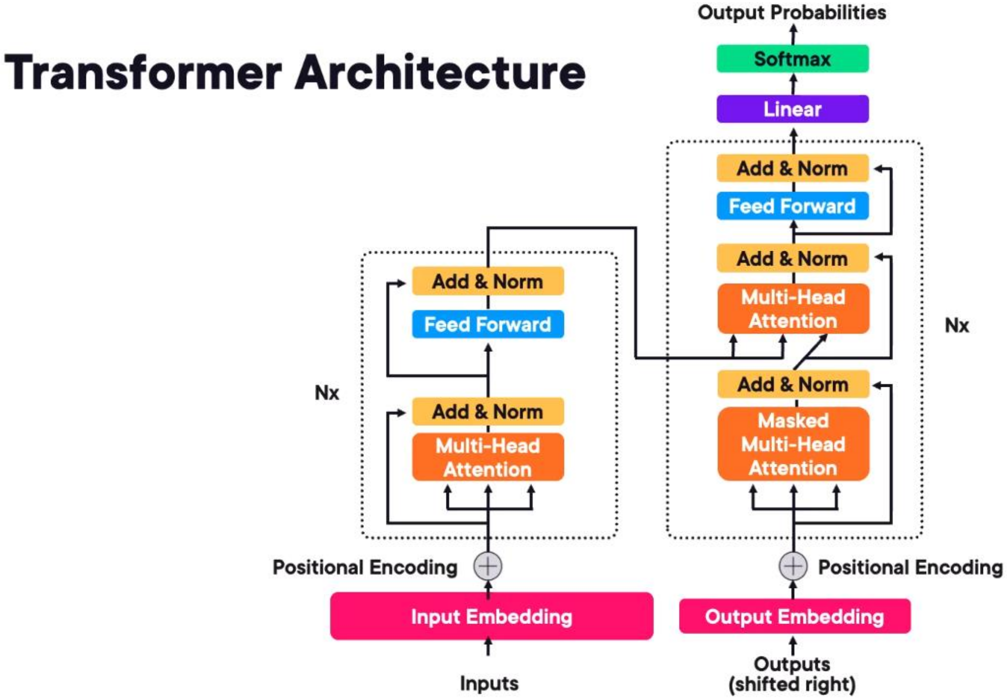

https://arxiv.org/pdf/1706.03762.pdf

Prédiction

Sur la base des embeddings traités

- À partir des tokens du prompt

Les modèles génèrent des prédictions pour le prochain token ou la prochaine séquence de token.

Le transformateur utilise le self-attention pour comprendre le contexte

- Il examine tous les mots de la phrase pour prédire chaque token
- L’attention est ce qui fait sa supériorité

Beam search

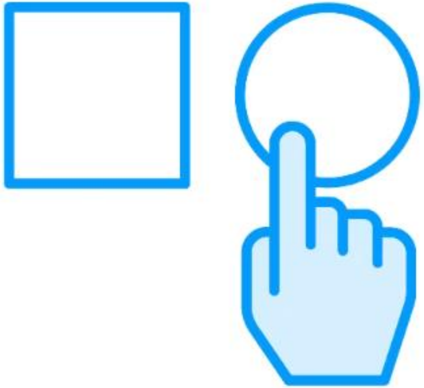

Le transformer utilise plusieurs approches pour sélectionner les mots
- À partir de la distribution prédite des mots

Il peut utiliser le Beam search
- Il examine la probabilité d'un ensemble plus large de mots et choisit le meilleur.

La phrase de sortie du LLMs

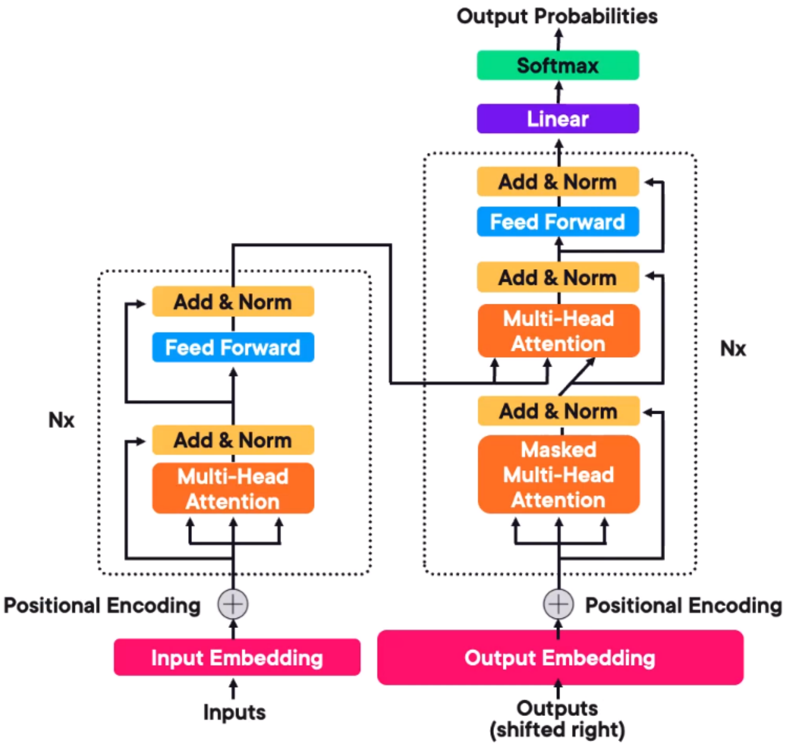

Exemple avec chatGPT

ChatGPT 3.5

You
Write a short story on a traveling computer programmer

output

ChatGPT
Once upon a time, in a world where technology intertwined with every aspect of life, there was a young computer programmer named Alex. Unlike most programmers who were content with their sedentary lifestyles, Alex had an insatiable wanderlust burning within.

From a young age, Alex was fascinated by computers. While other kids played outside, Alex was indoors, tinkering with code and building programs. As Alex grew older, the desire to explore the world outside the confines of their computer screen grew stronger.

One day, Alex made a bold decision. They packed up their laptop, a few changes of clothes, and set off on a journey across the globe. With nothing but their programming skills and a thirst for adventure, Alex embarked on an extraordinary journey.

Their first stop was in a bustling city where they found a cozy café with free Wi-Fi. With their laptop open, Alex dove into the local programming community, exchanging ideas and collaborating on projects. They quickly became known as the traveling programmer, a nomad of the coding world.

From there, Alex journeyed to remote villages where internet access was scarce. Undeterred, they

Message ChatGPT...

ChatGPT can make mistakes. Consider checking important information.

Ca ressemble à de la magie, mais c’est de l’informatique

Génération d’images

Partie 4 : L’IAG pour les développeurs

Génération d’images

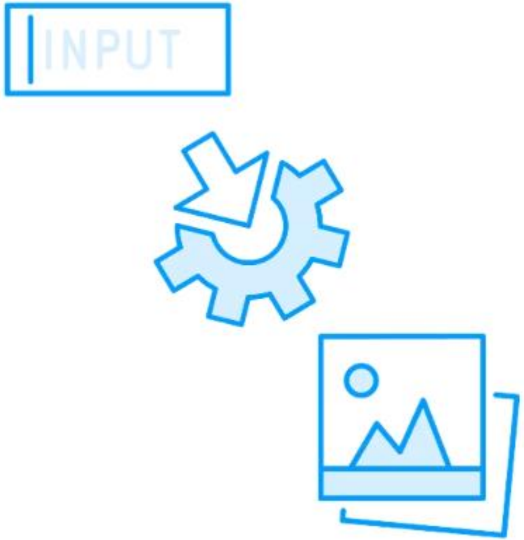

Les modèles d'IA sont utilisés pour générer de nouvelles images

- Sur la base d'un texte

Les résultats peuvent varier

- Des photographies réalistes,
- A des créations artistiques,
- Et tout ce qui se trouve entre les deux.

Plusieurs services existent

- Vous pouvez également entraîner vos propres modèles

Création d’images

- Dall-E 3 OpenAI
- Midjourney Midjourney

Data augmentation

- Mostly AI

Dall-E 3

ChatGPT 4

How can I help you today?

Make up a story
about Sharky, a tooth-brushing shark superh...

Compare design principles
for mobile apps and desktop software

Explain nostalgia
to a kindergartener

Write a text message
asking a friend to be my plus-one at a wedding

Create a photorealistic image of a 45-year old male riding a road bike up a steep hill.

ChatGPT can make mistakes. Consider checking important information.

Dall-E 3

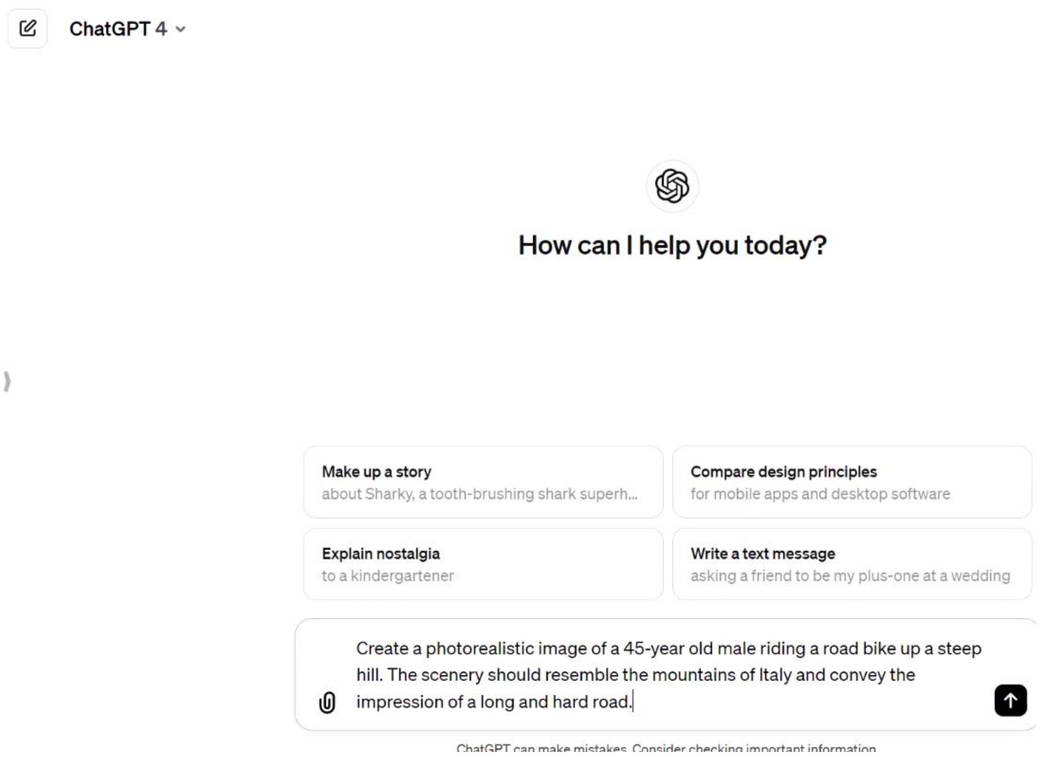
ChatGPT 4
How can I help you today?
Make up a story
about Sharky, a tooth-brushing shark superh...
Compare design principles
for mobile apps and desktop software
Explain nostalgia
to a kindergartener
Write a text message
asking a friend to be my plus-one at a wedding
Create a photorealistic image of a 45-year old male riding a road bike up a steep hill. The scenery should resemble the mountains of Italy and convey the impression of a long and hard road.
ChatGPT can make mistakes. Consider checking important information.

Dall-E 3

Quelques secondes de chargement

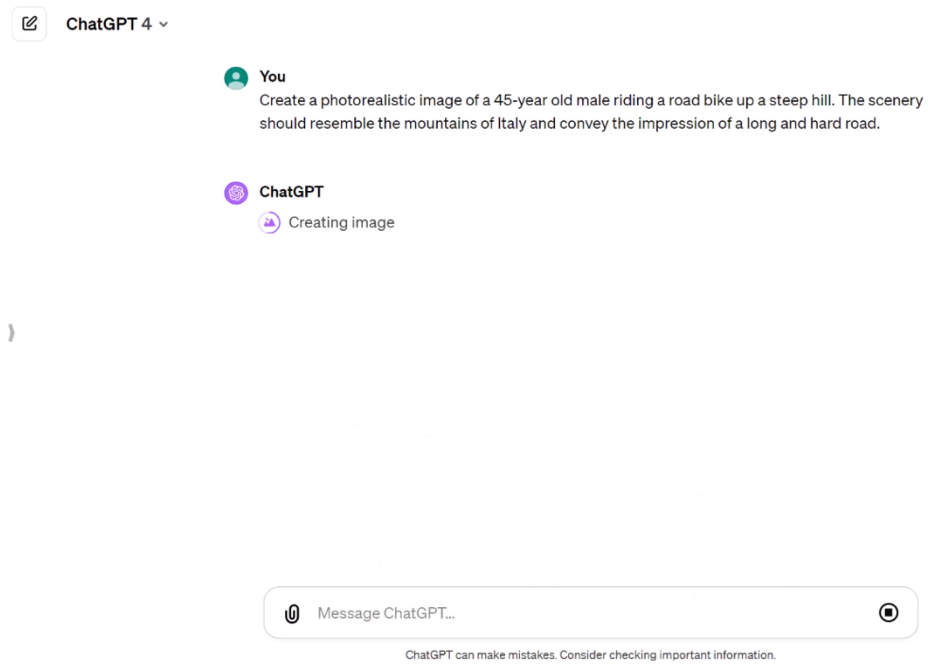

Dall-E 3

I've created a photorealistic image that captures the essence of a 45-year-old male riding a road bike up a steep hill in the Italian mountains. The image showcases the rugged terrain, the lush landscapes, and the determination of the rider as he faces the long and hard road ahead.

Mid-journey

Upscale les images

Créer des variations

Passer des paramètres pour contrôler la taille de l'image

Les différents types de modèle pour générer des images

Les Generatives Adversarial Networks (GANs)

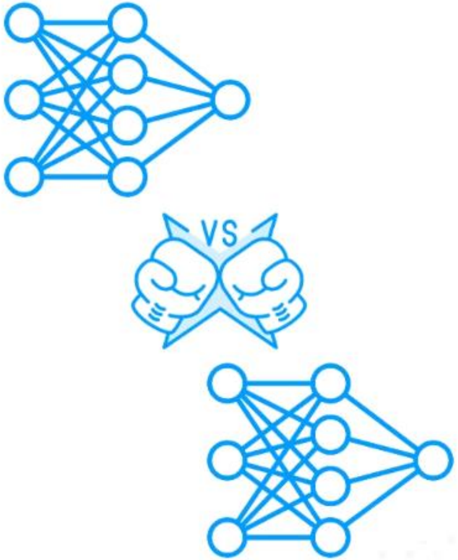

Consiste à entraîner deux réseaux de neurones
- Un générateur et un discriminateur

On entraîne les deux modèles en compétition l'un contre l'autre

Le générateur essaie de générer des images qui sont les plus indistinguables d'images réels.

Le discriminateur essaie de faire la différence entre les images générées et les images réelles.

L'entraînement continue jusqu'à ce que le discriminateur n'arrive plus à faire la différence entre une image réelle et une image générée

Transformers

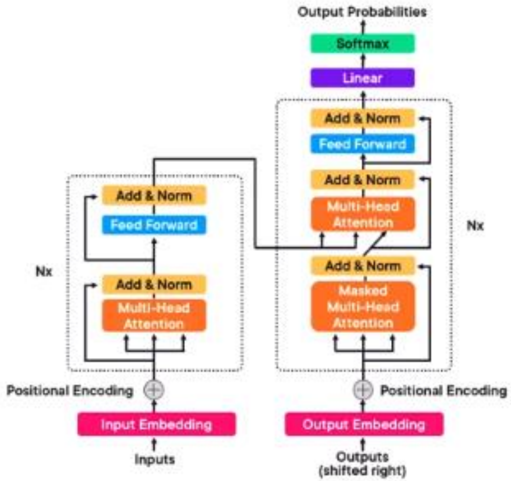

Il s'agit du même type de modèle utilisé pour la génération de texte, mais adapté à la création d'images.

Cette architecture est particulièrement intéressante car elle prend en compte les relations entre les différentes parties d'une image.

L'utilisation du mécanisme d'attention permet de se concentrer sur différentes zones des données d'entrée, ce qui facilite la création d'images très détaillées.

Variational Autoencoders (VAEs)

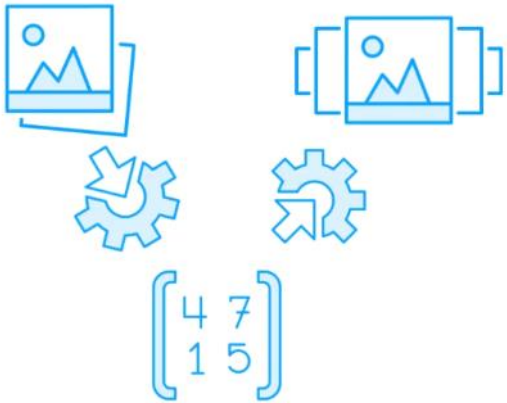

L’idée est d’encoder l’image dans un espace latent plus petit que la dimension d’origine et ensuite reproduire l’image originale dans sa dimension d’origine.

Variational Autoencoders (VAEs)

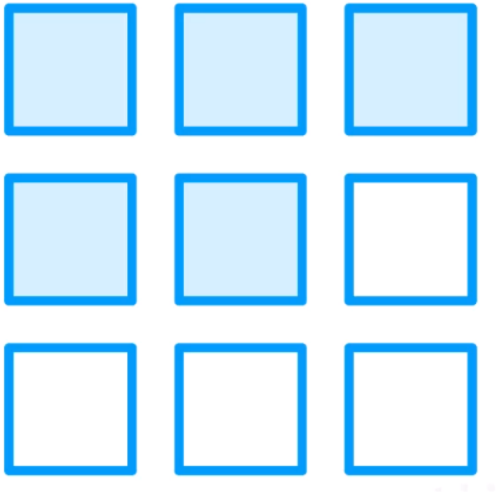

Génère des images pixel par pixel.

Traite le problème comme une génération de séquence.
- Chaque pixel est prédit basé sur le pixel précédent.

Permet de créer des images détaillés et cohérentes dans le temps.

Typiquement l’utilisation de RNNs ou CNNs pour capturer la dépendance entre les pixels.

Fonctionnement proche des imprimantes

Modèle de diffusion

Commence avec une image de bruit aléatoire

Puis change progressivement l'image de manière itérative
- Très gourmand en temps de calcul.

L'image final est cohérente

Créer et guidé par un réseau de neurone

Les images générées sont de grande qualité et en haute résolution avec différent style applicable.

La generation d’image est un domaine en rapide évolution

Génération de sons

Partie 4 : L’IAG pour les développeurs

Génération de son

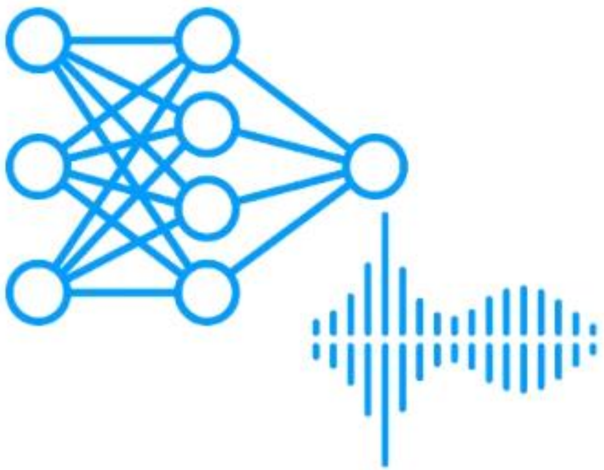

Création de contenus audio

- Génération de musique, de voix de synthèse, d’effets sonores, etc…
- Approche de son réel

Beaucoup de challenges et de choses à prendre en comptes:

- Les problèmes de copyrights, de biais, de diversité, d’authenticité, etc…

Création de musiques

- MusiqueLM — Google
- Sounddraw — Midjourney

Les types de modèles disponibles

- Generative Adversarial Networks
- Variational Autoencoders
- Autoregressive
- Transformers
- Recurrent Neural Networks
- Convolutional Neural Networks

The process de création de ces modèles

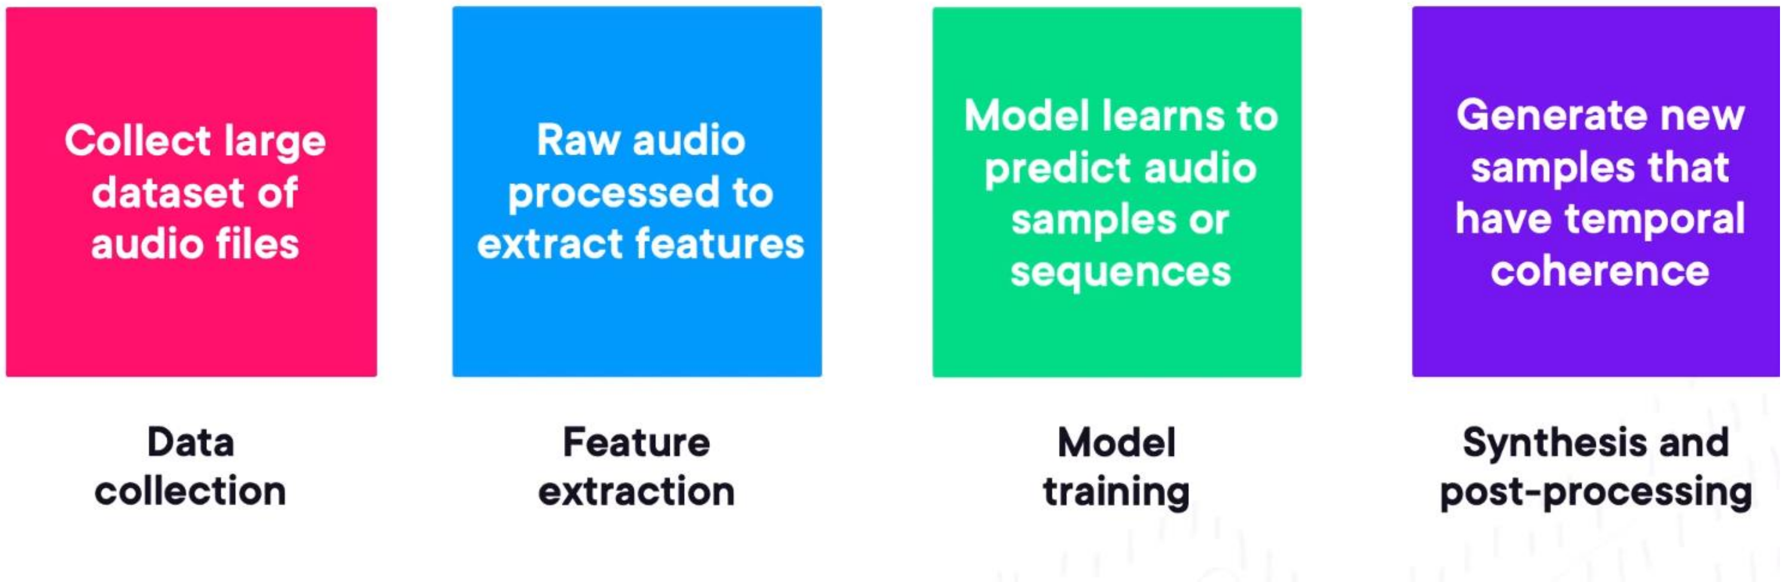

Applications

- Génération de musiques
- Génération d’effets sonores
- Text-to-speech et speech-to-text
- Voice cloning
- Tout ce que l’on peut imaginer grâce au son

Génération de vidéos

Partie 4 : L’IAG pour les développeurs

Création d’une image

Créer une image réaliste à partir d’un prompt est déjà un accomplissement considérable.

- Mais reste quelque chose de statique en deux dimensions
- On n'a pas de considération de temps ou de mouvements

Création d’une vidéo

Créer une vidéo c’est créer une série d’image qui change au fil du temps

- Le modèle doit savoir prendre en compte des séquences

Cela requière une profonde compréhension du contenu de l’image.

- Prendre le temps en considération
- Le mouvement doit être consistant dans le temps et doit correspondre à ce que l’on pourrait voir dans le monde réel

C’est très complexe et demande beaucoup de puissance de calcul

Le process est similaire avec l’image à une exception prêt

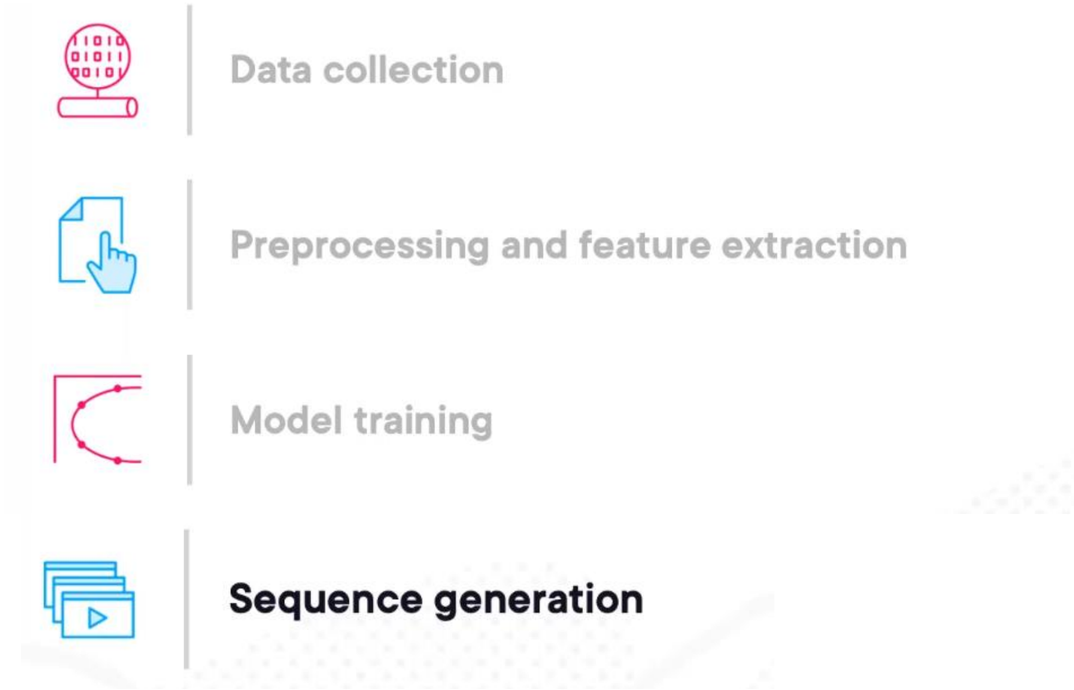

Génération de séquence

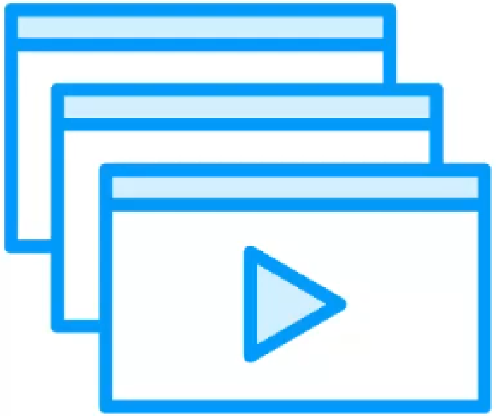

Le modèle apprend à prédire la prochaine image

- Dans une séquence
- Basé sur les images précédentes dans la séquence

Le modèle doit comprendre:

- L’aspect spatial de l’image,
- L’évolution du contexte avec le temps.

C’est une capacité essentielle pour créer des séquences d’images cohérentes qui permettent de créer des vidéos réalistes.

Les types de modèle pour générer des vidéos

Reccurent Neural Networks (RNNs)

Type of RNN that can remember long-term dependencies

Critical for understanding temporal dynamics in video data

Long Short-Term Memory (LSTM)

Similar to LTSM but with a simple structure

Can model time-series data effectively

Gated Recurrent Units (GRUs)

Generative Adversarial Networks (GANs)

Temporal GANs

GANs that are adapted for video

Includes mechanisms to capture the temporal progression between frames

MoCoGAN (Motion and Content decomposed GAN)

Divides video into content and motion

Allows for separate generation of static background and dynamic foreground

Transformer

Adaptation of the transformer architecture but for video generation

Video transformers

Variant of transformers that deals with video by incorporating temporal attention mechanisms

TimeSformer

Autres modèles

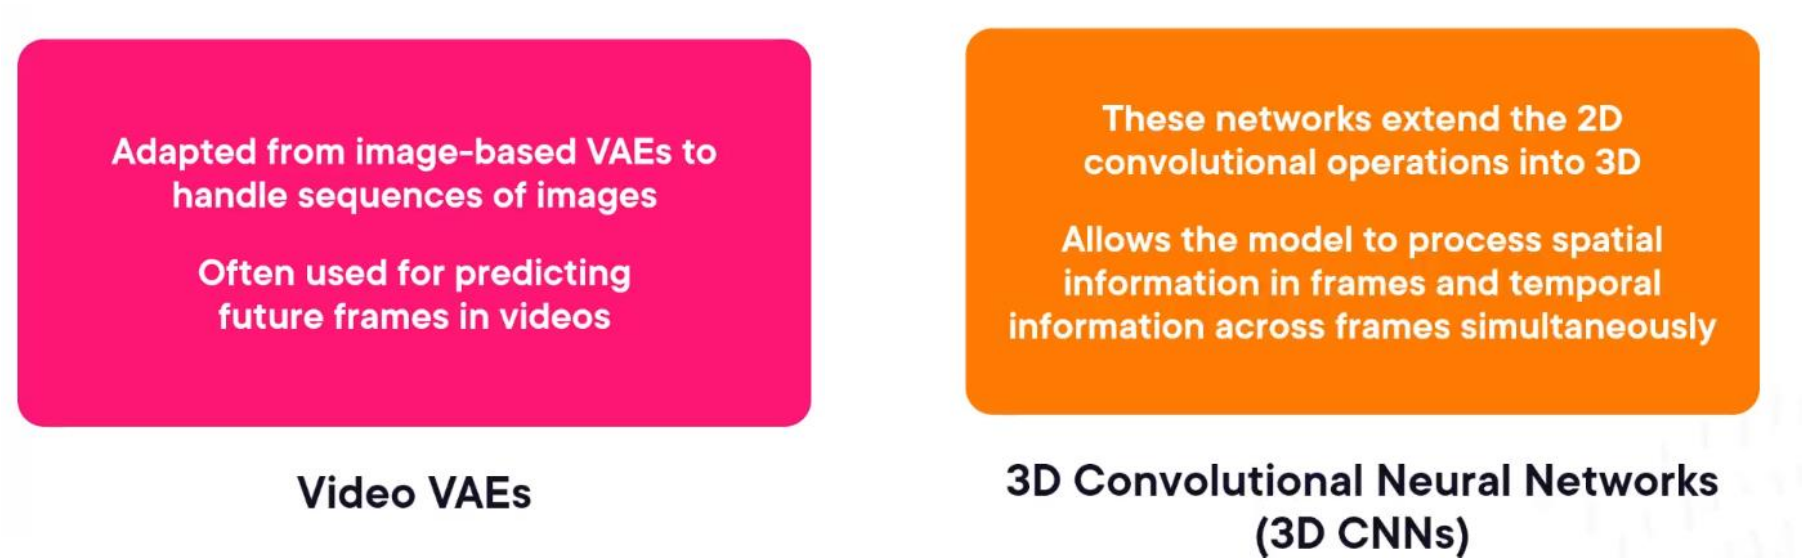

Autres modèles

Combine different architectures to leverage their strengths, for example:

- CNNs for spatial processing
- LSTMs for temporal processing

Hybrid Models

Use separate pathways to process spatial and temporal information

Typically, one stream with 2D CNNs for spatial

Another with 3D CNNs or optical flow for temporal aspects

Two-Stream Networks

Autres modèles

Generate videos by modeling the distribution of video data directly

Often using concepts like optical flow to ensure smooth transitions between frames

Flow-Based

Extended to video, they can generate videos pixel by pixel, frame by frame

They can be computationally intensive for practical use in video generation

Auto-regressive Models PixelCNNs and PixelRNNs

Autres modèles

Emerging architecture that tries to encode spatial hierarchies between features

Potentially useful for understanding complex spatial transformations in video

Capsule Networks

Applications de la création de vidéos

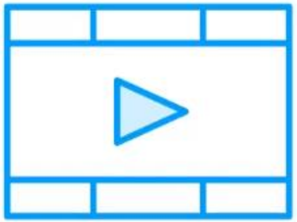

Chacun de ces modèles peuvent être appliqué à différentes tâches

- Prédiction de la prochaine image, super-résolution, vidéo en peinture, etc..

Les choix des modèles dépendent de la tâche à accomplir, des données à disposition et des structures de calcul disponible.

C’est encore un champ de cherche intensif.

Le modèle le plus intéressant actuellement est Sora d’OpenAI

Où trouvez des modèles open source ?

Partie 4 : L’IAG pour les développeurs

Hugging face

Mission :
Faciliter l’accès à l’IA et permettre à la communauté de collaborer autour des modèles et des données open source.

Hub de modèles

Les développeurs peuvent télécharger, partager ou ajuster ces modèles pour des tâches spécifiques comme la classification de texte, la génération de texte, ou encore la vision par ordinateur.

Exemples: Llama 2, GPT-NeoX, Bloom, Mistral,

Une librairie pour les transformers

Une bibliothèque Python qui simplifie l’utilisation des modèles de type Transformers (comme BERT, GPT, et T5).

Compatible TensorFlow et Pytorch

Des jeux de données disponibles

Une bibliothèque pour accéder, partager et préparer des ensembles de données utilisés dans le machine learning.

Exemple: IMDB, SQuAD, Common crawl, …